

DATA SCIENCE

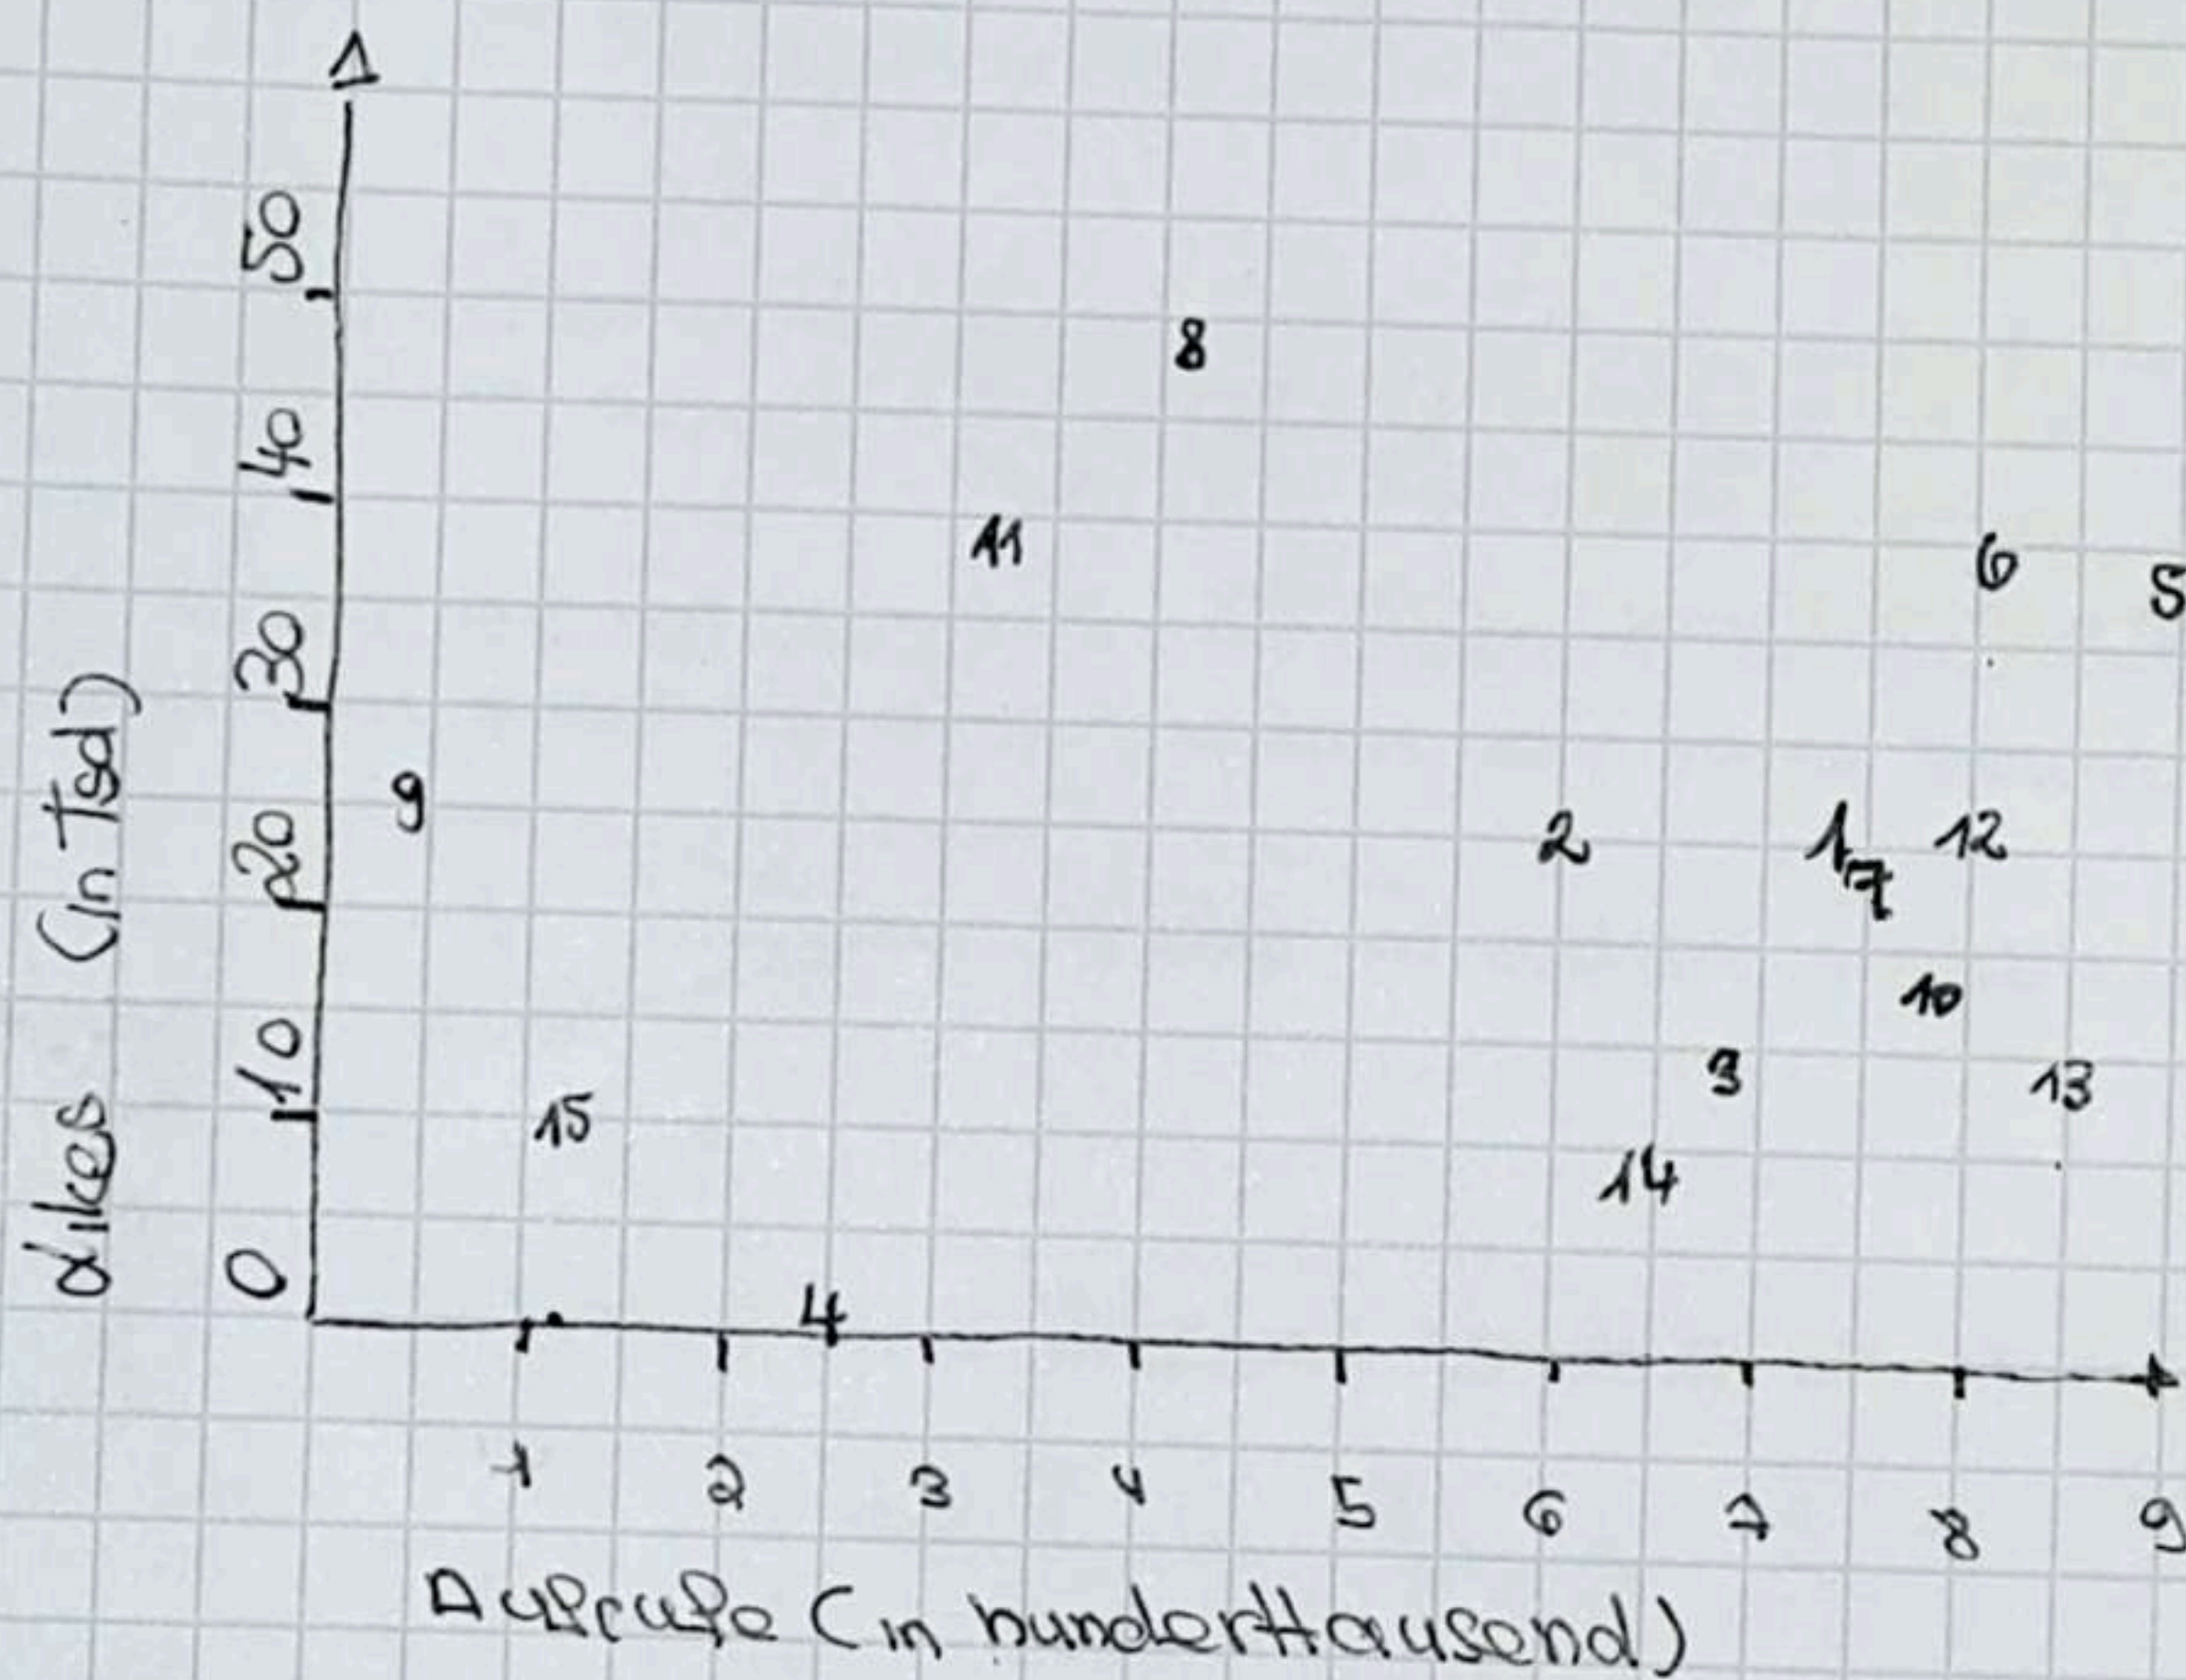
Praktikum 2

Fabian Gottong & Larissa Rychlau

D1

- a) Statistische Einheiten: "Videos"
 Merkmale: "Likes", "Aufrufe"
 Skalenniveau: kardinal (Verhältnisskala)

b)



"Likes" und "Views" korrelieren.

$$c) r = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2 \sum_{i=1}^n (Y_i - \bar{Y})^2}}$$

• Aufrufe: $580,93 = \sim 581$
 • Likes: $23,6 = \sim 24$

$$r = \frac{8797}{13100,48}$$

$$r = 0,67$$

x	NR x^2	NR Likes	Aufrufe
183	23409	25 - 24 = 1	734 - 581 = 153
28	784	25 - 24 = 1	608 - 581 = 28
1078	1.162.084	13 - 24 = -11	679 - 581 = 98
7458	55.621.264	2 - 24 = -22	242 - 581 = -339
4560	20.793.600	39 - 24 = 15	885 - 581 = 304
3712	13.778.944	40 - 24 = 16	813 - 581 = 232
0	0	24 - 24 = 0	757 - 581 = 176
-3956	15.649.936	47 - 24 = 23	409 - 581 = -172
-522	272.484	25 - 24 = 1	59 - 581 = -522
-1152	1.327.104	18 - 24 = -6	773 - 581 = 192
-3556	12.645.136	38 - 24 = 14	322 - 581 = -259
446	19.89.16	26 - 24 = 2	804 - 581 = 223
-2730	7.452.900	14 - 24 = -10	854 - 581 = 273
-1020	1.040.400	9 - 24 = -15	649 - 581 = 68
6454	41.654.116	10 - 24 = -14	120 - 581 = -461
	171622577		

d) Nicht zwingend, eine nicht-niedrig / überdurchschnittliche Like-Anzahl ist aber wahrscheinlich.

W2

$$a) p = 1 - \frac{6 \sum d_i^2}{n(n^2-1)} = 1 - \frac{6 \sum (R_{x_i} - R_{y_i})^2}{n(n^2-1)}$$

$$\Rightarrow p = 1 - \frac{6 \cdot 8}{9(9^2-1)} = 1 - \frac{48}{720} = 0,83$$

b) Die Zuordnung der nicht-numerischen Werte ist rein subjektiv. Eine andere Bewertung führt zu anderen Ergebnissen.

c) Es muss eine Ordinale Sortierung geben bzw. es müssen Objektive Standards (z.B. bpm) für die Sortierung gefunden werden.

NR		(x ²)	Test	
1	1	0	4	0
1	2	1	1	1
1	2	1	1	1
2	2	0	0	1
2	2	0	0	1
2	2	0	0	1
3	3	0	0	1
3	1	2	4	1
3	5	4	16	9
		8	20	16

2.3 WARSCHHEINLICHKEIT

Daten: 1000 zufällige Nutzer, die angerufen werden sollen
X Mitarbeiter die
O 10 Anrufe/Stunde schaffen

Wahrscheinlichkeitsmodelle

Die Mathematische Darstellung zufälliger Ereignisse.
Quantifizieren die Wahrscheinlichkeit mit d. Ereignisse eintreten

Verteilungen

Diskret • zählbare & abzählbare Ereignisse

stetig • kontinuierlicher Bereich v. Ereignissen → oft glatte Kurve im Modell

→ Hier vermutlich stetig

Binomialverteilung → Anzahl v. Erfolgen in Binären Ereignissen (unabhängige
n = Anzahl Versuche
p = Wahrscheinlichkeit jedes Versuchs
identisch)

Hypergeometrische Verteilung → Anzahl v. Erfolgen in Stichprobe (ohne
N = Gesamtzahl d. Elemente
K = Elemente m. relevanter Eigenschaft
n = Größe d. Stichprobe
Zurücklegen)

Poissonverteilung → misst Anzahl v. Ereignissen in Intervall (bei seltenen
λ = durchschnittliche Rate v. Ereignissen in Intervall
Ereignissen)

→ Hier vermutlich Poisson

Wir haben Intervalle, durchschnittliche Raten & Ereignisse

2.3. a)

Wir werden die Poissonverteilung nutzen

$$P(X) = \frac{e^{-\lambda} \lambda^k}{k!}$$

da wir eine zählbare, endliche Menge von Ereignissen mit Intervallen
und durchschnittlichen Ereignissraten haben

Parameter:

k (tatsächliche Anzahl v. Ereignissen im Intervall) = X = ?

λ (erwarteter Durchschnitt v. Ereignissen im Intervall) = 10

e (Eulersche Zahl) = ~ 2,71828

k! (das Produkt aller positiven ganzen Zahlen 1-k) = ?

2.3 b)

$$P(X=8) = \frac{e^{-\lambda} \lambda^k}{k!} = \frac{e^{-10} 10^8}{8!} = \sim 0.112599$$

mit 11,26 % Wahrscheinlichkeit mit der ein Mitarbeiter 8 Leute anruft

2.3 c)

hier wird die kumulierte Wahrscheinlichkeit von 0-8 anrufen benutzt:

$$\sum_{i=0}^8 \frac{e^{-\lambda} \lambda^i}{i!} = P(X \leq 8)$$

$$\Rightarrow \frac{e^{-10} 10^0}{0!} + \frac{e^{-10} 10^1}{1!} + \frac{e^{-10} 10^2}{2!} + \frac{e^{-10} 10^3}{3!} + \frac{e^{-10} 10^4}{4!} + \frac{e^{-10} 10^5}{5!} + \frac{e^{-10} 10^6}{6!} + \frac{e^{-10} 10^7}{7!} + \frac{e^{-10} 10^8}{8!}$$

\Rightarrow mit 33,28 % Wahrscheinlichkeit ruft d. Mitarbeiter maximal 8 Personen an

2.3 d)

Wir kumulieren die Wahrscheinlichkeit von $X < 8$

$$\rightarrow \sum_{i=0}^7 \frac{e^{-10} 10^i}{i!} \Rightarrow 22.02 \%$$

Das ziehen wir von 100 % ab

mit 77,78 % Wahrscheinlichkeit ruft d. Mitarbeiter mindestens 8 Personen an